5 RESULTADOS

Este capítulo apresenta os resultados das seis rodadas finais de reescrita e os diagnósticos que delimitam sua interpretação. A exposição acompanha o afastamento da notícia original, a mudança em cada transmissão, os contrastes entre perspectivas e geradores e a decomposição estrutural e afetiva do STDI. Em seguida, comparam-se Cluster e LLM no corpus inglês e os dois corpora pelo procedimento LLM comum. Uma análise exploratória relaciona características das notícias ao afastamento final, e a inspeção de casos explicita mudanças textuais e limites da mensuração.

Todos os números apresentados são resultados deste estudo. As notícias originais funcionam como referências textuais, sem serem tratadas como fatos externamente verificados. Consequentemente, deriva, contradição interna e alteração afetiva não são interpretadas como medidas de falsidade, crença, exposição ou compartilhamento humano. As configurações e as unidades de análise são aquelas descritas no Capítulo 4.

5.1 COBERTURA E ORGANIZAÇÃO DA ANÁLISE

As seis rodadas contêm 7.200 nós únicos de reescrita: 1.200 por combinação de corpus e gerador. Em cada rodada, as quatro árvores processaram as mesmas 50 entradas. Todos os nós apresentam reescrita concluída e STDI selecionado válido, tanto contra o original quanto contra o pai efetivo. A projeção nas oito trajetórias contém 9.600 posições, ou 1.600 por rodada, porque repete os prefixos compartilhados. Essas posições não representam gerações adicionais.

Tabela 4 – Cobertura dos resultados finais utilizados no capítulo.

Corpus	Gerador	Entradas	Nós únicos	Posições	STDI válido
Inglês	GPT	50	1.200	1.600	1.200/1.200
Inglês	Grok	50	1.200	1.600	1.200/1.200
Inglês	Gemini	50	1.200	1.600	1.200/1.200
Português	GPT	50	1.200	1.600	1.200/1.200
Português	Grok	50	1.200	1.600	1.200/1.200
Português	Gemini	50	1.200	1.600	1.200/1.200

Fonte: elaboração própria. A última coluna refere-se separadamente a cada referência de comparação: original e pai efetivo.

As abreviações GPT, Grok e Gemini correspondem aos geradores identificados na Tabela 2. Nas comparações principais, preservam-se as configurações selecionadas: STDI/VAD Dual em inglês e LLM/LLM em português. O recorte explicitamente identificado como LLM utiliza comparação estrutural LLM e VAD LLM em ambos os corpora.

A notícia é a unidade de pareamento dentro de cada corpus. Tabelas de resultados finais utilizam 50 escores por trajetória e gerador. As curvas mostram a mediana e o intervalo entre o primeiro e o terceiro quartil; os boxplots apresentam a distribuição entre notícias, com pontos individuais. Essas faixas descrevem dispersão, e não intervalos de confiança. As diferenças entre trajetórias são calculadas para a mesma entrada antes da agregação. Não se contam posições, avaliações repetidas do juiz ou respostas reutilizadas como notícias independentes.

Optou-se por uma apresentação descritiva, sem testes de hipótese ou intervalos populacionais. A seleção intencional das entradas, a existência de coberturas relacionadas de um acontecimento e a ausência de repetições independentes da geração limitam a generalização dos resultados. Correlações e diferenças médias indicam padrões no conjunto observado, sem estabelecer causalidade ou superioridade factual de um método.

Os agregados e as figuras foram produzidos a partir dos 24 arquivos de nós das rodadas finais pelo script `scripts/analyze_tcc_chapter_5.py`. Os dados derivados, os critérios de seleção de casos e os hashes das fontes estão preservados em `output/analysis/tcc_chapter_5/`. Foram conferidos a identidade dos textos originais entre condições, os prefixos compartilhados, a soma dos incrementos e a composição do Dual a partir dos ramos com VAD comum. O processamento não realizou novas chamadas aos modelos.

5.2 DIAGNÓSTICOS ANTERIORES DO INSTRUMENTO

Os diagnósticos iniciais apresentados no Capítulo 3 motivaram a passagem da classificação binária para a descrição de transformações graduais. Eles não integram as seis rodadas finais nem constituem uma avaliação factual dessas saídas. Em particular, um detector manter a mesma classe enquanto um texto é reescrito não demonstra preservação de conteúdo, assim como uma alteração detectada pela auditoria não estabelece falsidade externa.

Uma evidência delimitada sobre o comportamento do STDI é a auditoria controlada corrigida de 5 de outubro, identificada como `STDIControlledInformationAudit_20261005` no diretório `output/audit/`. Os dois comparadores produziram escores completos nos 36 pares primários, construídos a partir de três cenários fictícios e doze tipos de variante. A Tabela 5 apresenta um recorte dos resultados. As expectativas de ordenação foram atendidas em seis dos nove contrastes pelo Cluster e em nove pelo LLM; são expectativas das construções, sem referência humana numérica independente.

Naquele recorte, o Cluster atribuiu maior deriva às paráfrases do que o LLM, enquanto o LLM respondeu mais intensamente à negação e à troca de ator. A inspeção de uma paráfrase do cenário eleitoral mostrou a ausência de uma entidade na extração, embora ela permanecesse no texto. O diagnóstico evidencia que um escore pode refletir diferenças de representação, além da transformação textual pretendida. A auditoria utilizou

Tabela 5 – STDI médio de variantes selecionadas na auditoria controlada de 5 de outubro.

Variante	Cluster	LLM
Identidade	0,000	0,000
Paráfrase	0,122	0,002
Negação	0,162	0,439
Troca de ator	0,147	0,292
Mudança de quantidade	0,131	0,229
Omissão	0,455	0,338
Contradição interna	0,396	0,484

Fonte: elaboração própria, a partir de `change_type_summary.csv` da auditoria. Cada média utiliza três cenários pareados, com VAD BERT comum.

`structured_extraction_v4`, `structured_judge_v3`, `cluster_v3` e `dual_stdi_v3`; seus números não são atribuídos às versões finais nem apresentados como validação automática da ampliação posterior dos qualificadores numéricos.

O piloto afetivo de 6 de outubro, preservado em `output/audit/LLMVADComparison_20261006/`, também registrou diferenças entre estimadores. Nos 30 pares de simulação, derivados de cinco notícias em seis cadeias anteriores, a deriva VAD média foi 0,01986 com BERT e 0,07167 com LLM. Nos vinte controles sintéticos, as médias foram 0,05450 e 0,06250. A amplitude nominal comum não eliminou as diferenças de comportamento. Esses resultados exploratórios contribuíram para a escolha metodológica, mas maior variação não demonstra maior acurácia, e a rubrica daquele piloto deve ser distinguida da versão `v2` utilizada nas rodadas finais.

Os controles, os 50 pares históricos e os casos diagnósticos de desenvolvimento são conjuntos distintos. Nenhum deles é somado às notícias finais como um conjunto humano anotado. A análise seguinte examina os textos efetivamente gerados nas seis condições finais.

5.3 EVOLUÇÃO DO STDI NAS TRAJETÓRIAS

5.3.1 Afastamento em relação ao original

A Figura 1 apresenta O_t, definido na Equação 4.9. NNNN permanece com os menores valores em todas as condições. As trajetórias iniciadas por C, P ou D apresentam afastamento já na primeira posição; NNDD acompanha NNNN até a segunda posição e se separa após a introdução de D. A coincidência dos prefixos representa a mesma saída compartilhada, e não a convergência de gerações independentes.

A Tabela 6 complementa as curvas com médias finais. Em inglês, NNNN varia de 0,120 com Grok a 0,163 com GPT; em português, de 0,013 com Grok a 0,084 com GPT. Os valores ingleses e brasileiros desta tabela usam configurações diferentes e não são interpretados como efeito do idioma. Entre as trajetórias interpretativas, as médias finais

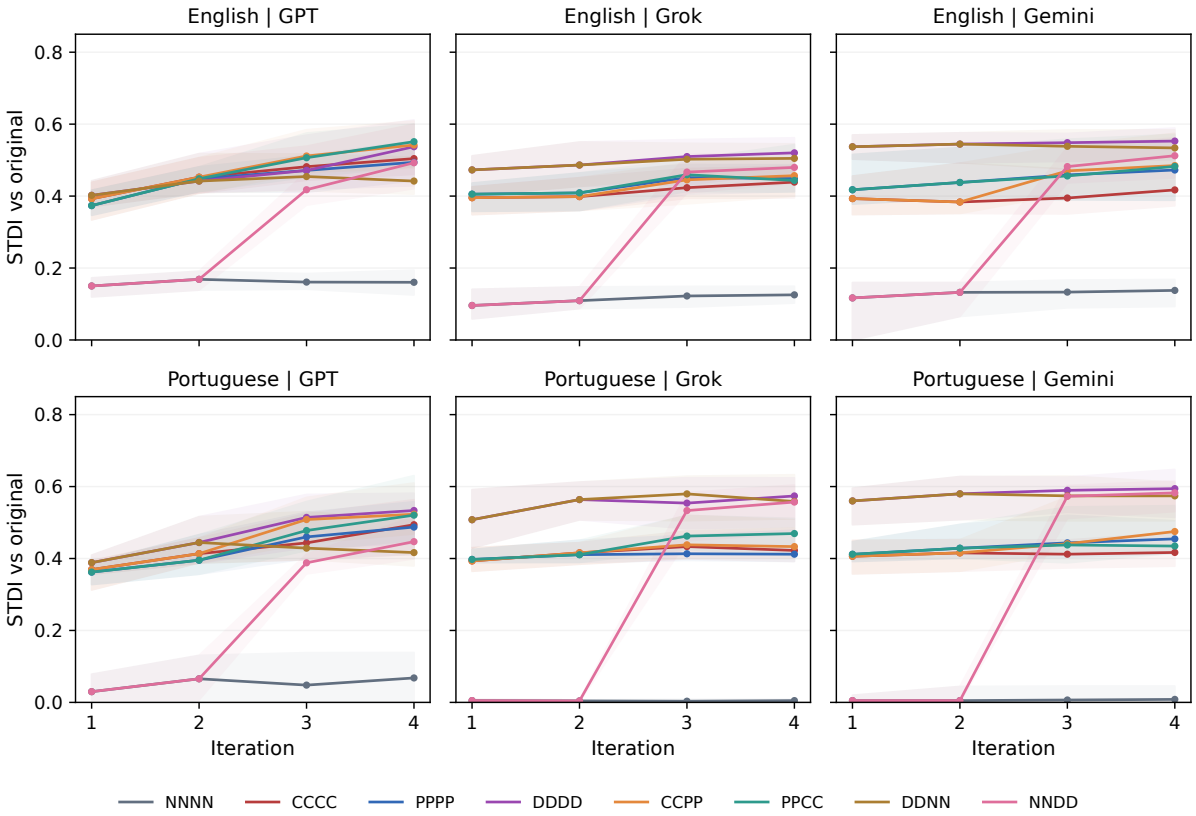


Figura 1 – Evolução do STDI contra o original nas seis rodadas. Linhas: medianas; faixas: intervalos interquartis de 50 notícias. Inglês utiliza Dual/Dual e português, LLM/LLM.

Fonte: elaboração própria. Os rótulos dos gráficos são mantidos em inglês.

Tabela 6 – STDI médio final contra o original nas configurações selecionadas.

	Inglês			Português		
Trajetória	GPT	Grok	Gemini	GPT	Grok	Gemini
NNNN	0,163	0,120	0,124	0,084	0,013	0,032
CCCC	0,522	0,433	0,421	0,490	0,436	0,432
PPPP	0,503	0,453	0,474	0,493	0,438	0,465
DDDD	0,523	0,513	0,532	0,520	0,557	0,576
CCPP	0,542	0,459	0,499	0,539	0,456	0,497
PPCC	0,542	0,467	0,483	0,530	0,467	0,467
DDNN	0,458	0,496	0,521	0,446	0,560	0,563
NNDD	0,499	0,477	0,504	0,458	0,544	0,571

Fonte: elaboração própria. 50 entradas por célula. Inglês: Dual/Dual; português: LLM/LLM.

situam-se entre 0,421 e 0,542 em inglês e entre 0,432 e 0,576 em português.

O padrão varia com o gerador. Em GPT, CCPP e PPCC apresentam os maiores escores médios finais nos dois corpora, com valores próximos entre si. Em Grok e Gemini, as trajetórias com D concentram parte dos maiores afastamentos: no português, DDDD alcança 0,557 com Grok e 0,576 com Gemini, enquanto DDNN permanece em 0,560 e 0,563. Esses agregados não indicam que todas as notícias sigam a mesma ordenação.

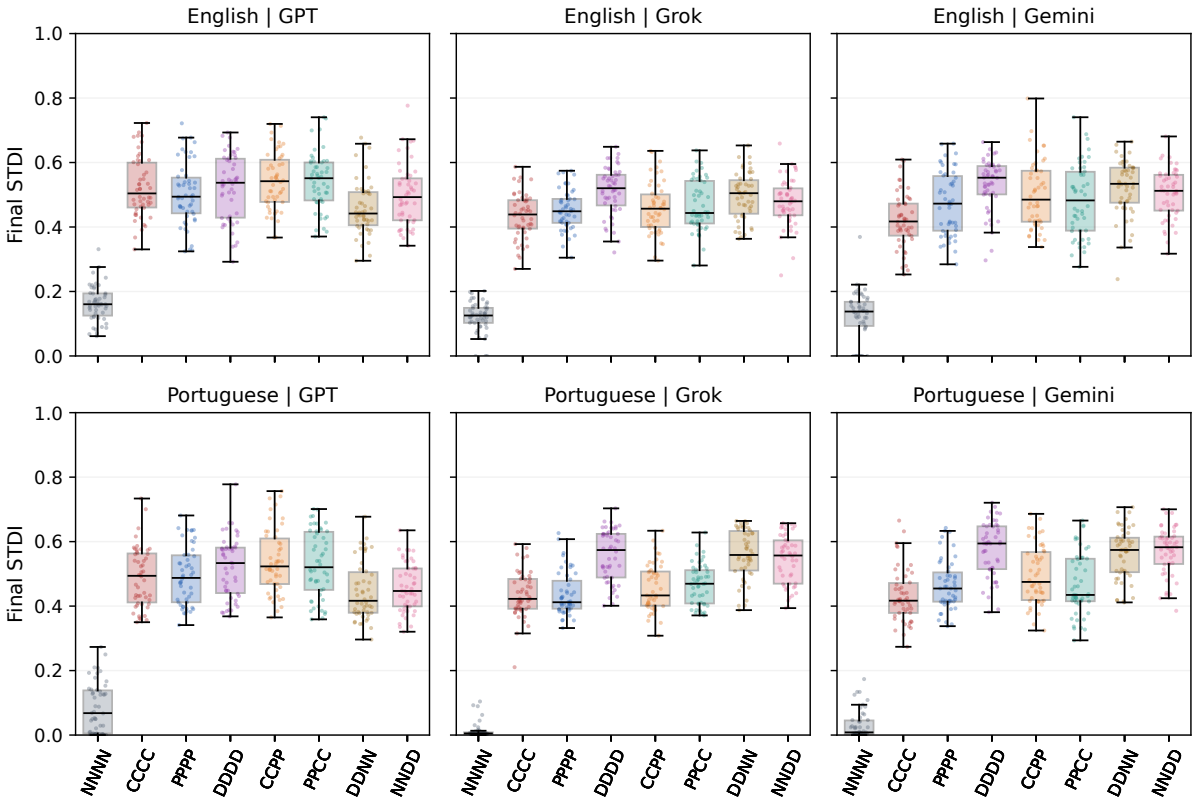


Figura 2 – Distribuição do STDI contra o original na quarta posição. Cada ponto representa uma notícia; caixas: intervalo interquartil e mediana; hastes: regra de 1,5 intervalo interquartil. Todos os pontos são exibidos, inclusive os externos às hastes.

Fonte: elaboração própria. 50 entradas por trajetória e gerador.

Os boxplots da Figura 2 mostram sobreposição entre várias trajetórias interpretativas e a presença de casos afastados da região central. A diferença entre médias deve, portanto, ser lida juntamente com a distribuição e com as comparações pareadas. A separação de NNNN é mais regular que a ordenação entre CCCC, PPPP e as sequências mistas.

5.3.2 Mudança produzida em cada passagem

O STDI incremental I_t, definido na Equação 4.10, descreve a diferença entre a saída e o pai efetivo. A Figura 3 mostra o aumento associado à terceira posição de NNDD e das

sequências que trocam C por P ou P por C. Em DDNN, as posições neutras apresentam mudança menor que as posições conspiratórias iniciais, embora o afastamento do original permaneça elevado.

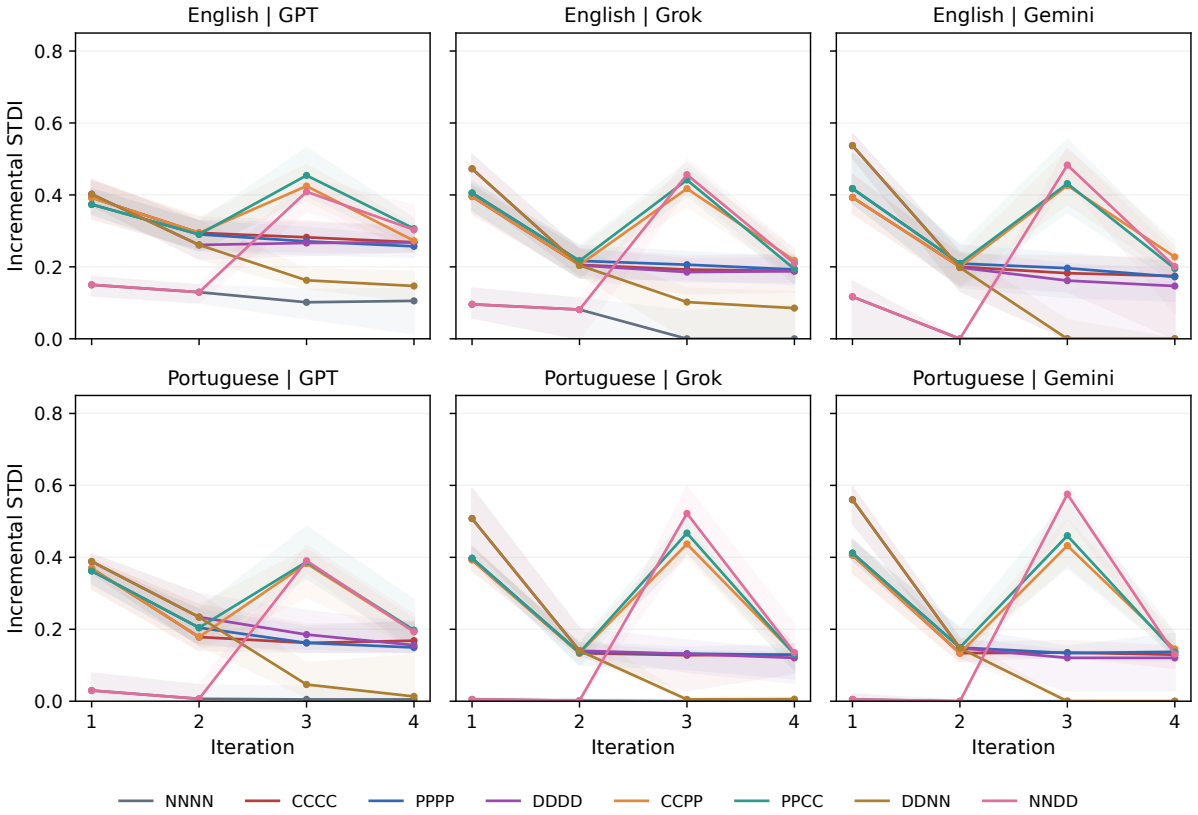


Figura 3 – STDI incremental nas quatro posições. A referência de cada ponto é o texto recebido pelo agente daquela posição. Linhas: medianas; faixas: intervalos interquartis.

Fonte: elaboração própria. Configurações selecionadas e 50 entradas por curva.

Na quarta posição de DDNN, o incremento médio é 0,150, 0,071 e 0,043 em inglês, para GPT, Grok e Gemini, respectivamente; em português, é 0,057, 0,012 e 0,014. Esses números coexistem com afastamentos finais entre 0,446 e 0,563 nessa trajetória. A baixa mudança local não significa recuperação do original: pode representar preservação da mensagem já transformada.

GPT também apresenta incrementos finais maiores que os outros geradores nas trajetórias interpretativas em ambos os corpora. Por exemplo, em CCPP, as médias são 0,284 em inglês e 0,207 em português, diante de 0,202 e 0,157 com Gemini. São comparações das saídas observadas; a geração não foi repetida independentemente para estimar a variabilidade entre novas execuções.

Tabela 7 – STDI incremental médio na quarta posição.

	Inglês			Português		
Trajetória	GPT	Grok	Gemini	GPT	Grok	Gemini
NNNN	0,092	0,040	0,012	0,019	0,003	0,003
CCCC	0,279	0,172	0,142	0,183	0,110	0,118
PPPP	0,264	0,188	0,159	0,181	0,114	0,143
DDDD	0,274	0,192	0,115	0,188	0,104	0,097
CCPP	0,284	0,215	0,202	0,207	0,129	0,157
PPCC	0,298	0,186	0,194	0,223	0,130	0,150
DDNN	0,150	0,071	0,043	0,057	0,012	0,014
NNDD	0,307	0,200	0,166	0,205	0,150	0,125

Fonte: elaboração própria. 50 entradas por célula. Inglês: Dual/Dual; português: LLM/LLM.

5.3.3 Aumento ou redução do afastamento e soma dos incrementos

Para distinguir mudança local de mudança no afastamento, calcula-se, a partir da segunda posição,

$$\Delta O_t = O_t - O_{t-1}, \qquad t \in \{2, 3, 4\}. \tag{5.1}$$

Um valor negativo indica menor escore contra o original, e não um incremento negativo. Como I_t e ΔO_t comparam objetos distintos, uma passagem pode apresentar mudança local e reduzir o afastamento medido contra a referência inicial.

O afastamento não cresce monotonicamente em todas as notícias. Entre as 1.200 transições projetadas das posições dois a quatro de cada rodada, ocorreram reduções do escore em 320, 372 e 300 posições inglesas e em 311, 374 e 363 posições brasileiras, para GPT, Grok e Gemini, respectivamente. Esses denominadores incluem prefixos repetidos nas projeções e descrevem transições de trajetórias, sem representar observações independentes. A Seção 5.9 mostra que algumas reduções acompanham mudanças pequenas de redação, o que impede interpretá-las automaticamente como restauração informacional.

A soma B_4 dos quatro incrementos também difere do afastamento final. Ao atribuir o mesmo peso às oito trajetórias, sua média varia de 0,877 a 1,124 em inglês e de 0,756 a 0,854 em português; as médias correspondentes de O_4 variam de 0,427 a 0,469 e de 0,434 a 0,450. A soma descreve o percurso de mudanças e pode ultrapassar um, sem representar percentual de informação perdida.

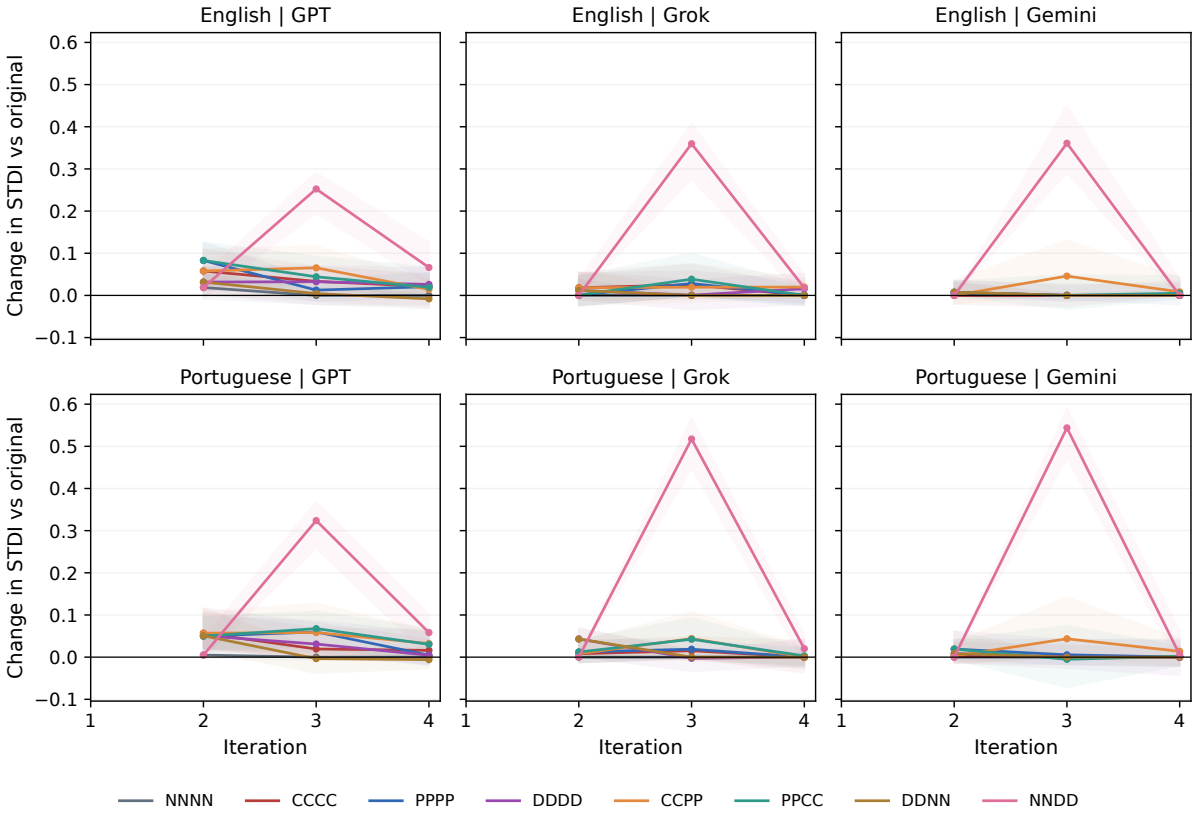


Figura 4 – Variação do STDI contra o original entre posições consecutivas. O eixo zero separa aumento e redução do escore. Linhas: medianas; faixas: intervalos interquartis.

Fonte: elaboração própria. A primeira posição não possui diferença anterior nesta análise.

5.4 CONTRASTES ENTRE PERSPECTIVAS, SEQUÊNCIAS E GERADORES

A Tabela 8 apresenta diferenças médias calculadas por notícia na quarta posição. Nos quatro primeiros contrastes, as duas trajetórias compartilham as saídas iniciais e diferem na continuação. Os dois últimos comparam sequências de mesma composição, com posições e perspectiva final diferentes.

Tabela 8 – Diferenças médias pareadas entre trajetórias na quarta posição.

	Inglês			Português		
Contraste	GPT	Grok	Gemini	GPT	Grok	Gemini
NNDD-NNNN	0,336	0,357	0,380	0,373	0,531	0,539
CCPP-CCCC	0,020	0,025	0,079	0,048	0,021	0,066
PPCC-PPPP	0,039	0,014	0,009	0,037	0,030	0,002
DDNN-DDDD	-0,064	-0,017	-0,010	-0,074	0,004	-0,013
CCPP-PPCC	-0,000	-0,008	0,017	0,009	-0,011	0,030
NNDD-DDNN	0,040	-0,019	-0,017	0,012	-0,016	0,008

Fonte: elaboração própria. 50 diferenças por célula; valor positivo indica maior STDI na primeira trajetória.

NNDD apresenta STDI final maior que NNNN nas 50 entradas de cada rodada. A diferença média vai de 0,336 a 0,380 em inglês e de 0,373 a 0,539 em português. É o contraste de direção mais consistente entre os examinados: continuar a retransmissão neutra e introduzir D após NN produzem resultados distintos para todas as entradas observadas.

As mudanças CCPP–CCCC e PPCC–PPPP também apresentam diferenças médias positivas nas seis condições. Entretanto, a direção não é uniforme entre notícias. Em CCPP–CCCC, a fração de diferenças positivas varia de 58% a 82%; em PPCC–PPPP, de 54% a 68%. A mudança de perspectiva está associada a maior afastamento médio nesses contrastes, mas não permite afirmar que toda troca aumenta o STDI.

DDNN–DDDD apresenta diferença média negativa em cinco das seis condições. A exceção é Grok em português, com diferença de 0,004. Em GPT, a redução média é 0,064 em inglês e 0,074 em português; em Gemini, é 0,010 e 0,013. A retransmissão neutra interrompe parte da mudança incremental, mas seus textos finais ainda conservam afastamento elevado. Além disso, DDNN e DDDD compartilham apenas as duas primeiras posições: a comparação final envolve duas continuações distintas, e não a correção de um mesmo texto final.

As comparações de composição invertida são menores e menos regulares. CCPP–PPCC varia de $-0,011$ a 0,030 entre as seis condições. NNDD–DDNN varia de $-0,019$ a 0,040, com mudança de sinal entre geradores e corpora. A Figura 5 evidencia essa heterogeneidade. Não se encontra uma direção única para as inversões consideradas, e o desenho não separa a ordem das posições ocupadas e da perspectiva final.

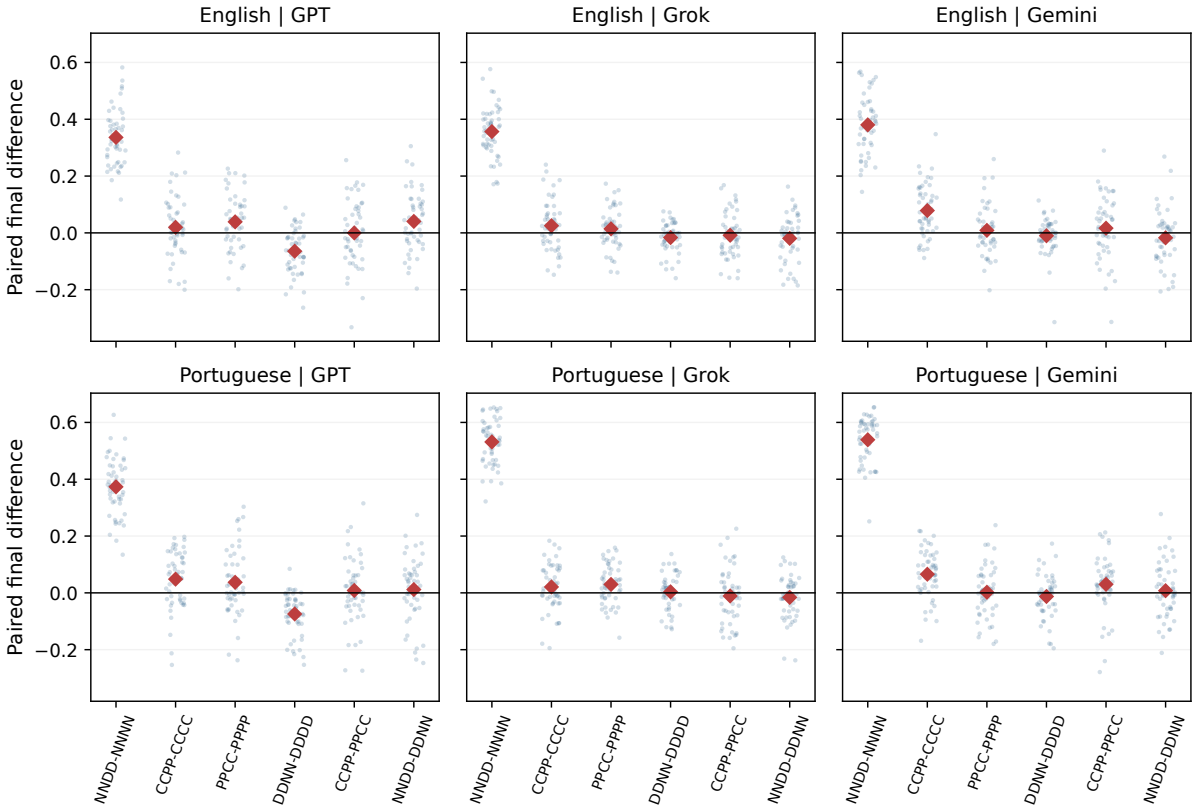


Figura 5 – Diferenças pareadas de STDI final entre trajetórias. Pontos azuis: diferenças por notícia; losangos vermelhos: médias de 50 diferenças. A referência zero indica igualdade entre os escores.

Fonte: elaboração própria. Valores positivos indicam maior escore na primeira trajetória do contraste.

As diferenças entre geradores dependem da trajetória. Em inglês, GPT apresenta maior média final que Grok e Gemini em CCPP e PPCC, mas não em DDDD, cuja maior média selecionada é a de Gemini. Em português, GPT supera os outros dois em CCPP e PPCC, enquanto Grok e Gemini apresentam maiores escores que GPT nas três trajetórias DDDD, DDNN e NNDD. Portanto, um ranking único de geradores ocultaria a associação entre modelo, perspectiva e caminho. Essas comparações são pareadas dentro do corpus; não envolvem pareamento entre as notícias inglesas e brasileiras.

5.5 DECOMPOSIÇÃO E DIREÇÃO AFETIVA

A Figura 6 apresenta as médias dos componentes contra o original na quarta posição. Ao considerar as oito trajetórias com o mesmo peso, subtópicos e relações têm as maiores médias de deriva de conteúdo nas seis condições. A deriva média de subtópicos varia de 0,566 a 0,585; a de relações, de 0,506 a 0,559. Entidades apresentam médias de 0,222 a 0,366 e tema, de 0,265 a 0,370. Esses valores descrevem componentes operacionais, sem

equivaler a frações de fatos perdidos.

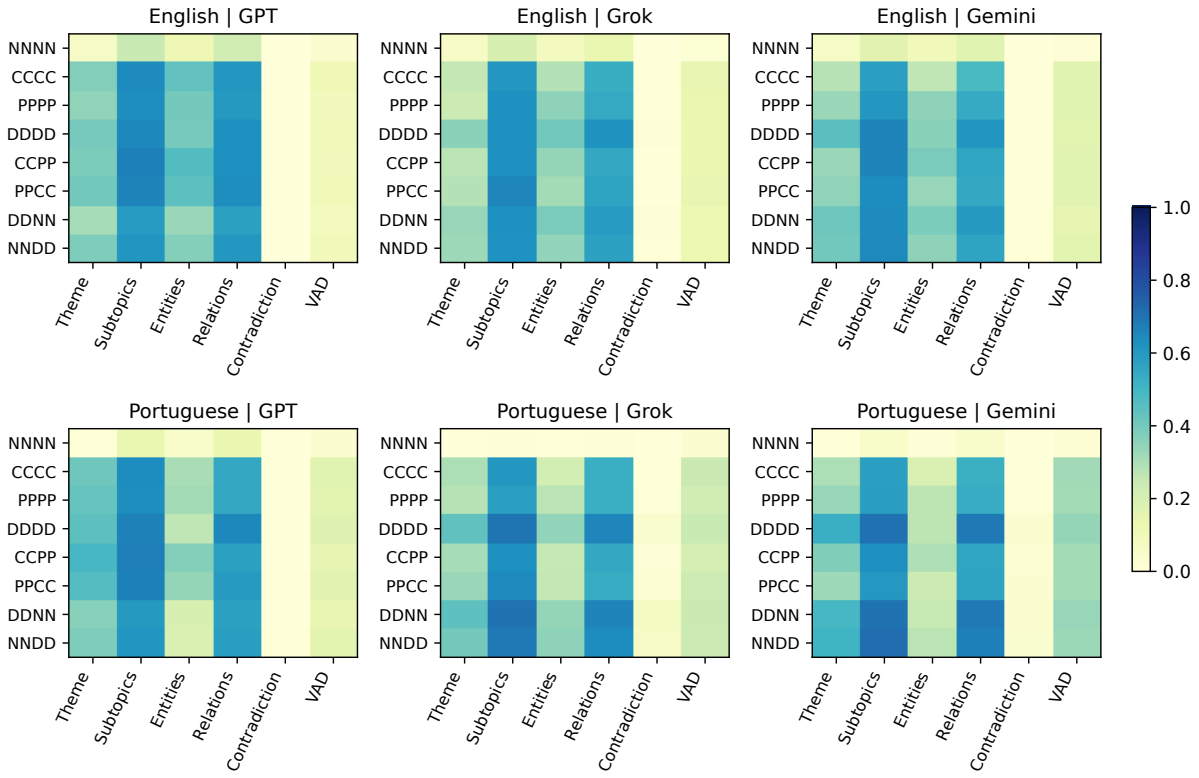


Figura 6 – Médias dos componentes na quarta posição, por trajetória, corpus e gerador. Cada célula utiliza 50 entradas; a escala de cores é comum aos painéis.

Fonte: elaboração própria. Inglês: componentes do Dual selecionado; português: componentes do LLM selecionado.

A contradição interna apresenta médias menores: entre 0,0002 e 0,0044 em inglês e entre 0,0017 e 0,0269 em português. Ela é não nula em duas, quatorze e treze das 400 posições finais inglesas e em seis, 38 e 42 posições brasileiras, para GPT, Grok e Gemini. A unidade dessa contagem é a posição final de uma trajetória; as mesmas 50 notícias participam dos oito caminhos. Baixa contradição interna não demonstra veracidade nem ausência de transformação: é possível construir um relato internamente coerente e distante da entrada.

Os componentes não devem ser somados diretamente para reconstruir o STDI completo. Os quatro componentes de conteúdo têm pesos iguais, enquanto contradição e VAD utilizam a distância restante, conforme o Capítulo 4. Além disso, o ramo LLM é agregado a partir de escores completos de avaliações repetidas. O mapa de calor permite localizar padrões de mudança, sem apresentar contribuições como parcelas aditivas simples.

Para observar a direção afetiva, a Figura 7 utiliza os valores brutos do VAD LLM, calculando a diferença entre a versão final e o original em cada dimensão. Esse recorte emprega o mesmo tipo de estimador nos dois corpora. Não se constrói um vetor bruto

Dual, pois esse método combina derivas normalizadas, e não os vetores antes da distância.

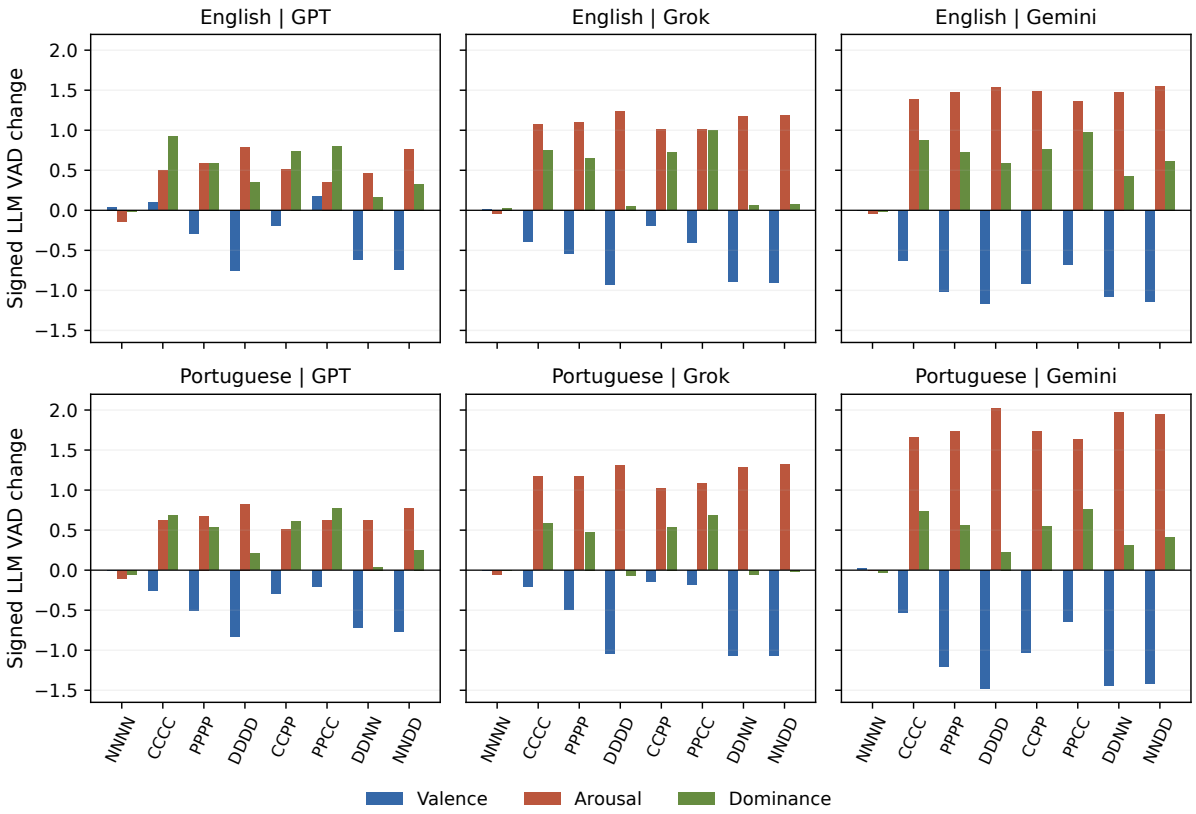


Figura 7 – Mudanças médias com sinal em valência, ativação e dominância, estimadas pelo LLM entre original e quarta posição. Valores positivos indicam aumento na dimensão, na escala nominal de um a cinco.

Fonte: elaboração própria. Cada barra utiliza 50 pares; dimensões afetivas não medem emoção do leitor.

Em DDDD, DDNN e NNDD, a valência média diminui e a ativação aumenta em todos os geradores e corpora. Em DDDD, a mudança média de valência vai de $-0,758$ a $-1,162$ em inglês e de $-0,832$ a $-1,476$ em português. A ativação nessa trajetória aumenta entre 0,794 e 1,542 em inglês e entre 0,826 e 2,022 em português. NNNN apresenta mudanças próximas de zero em comparação com essas trajetórias.

As dimensões não se movem de maneira uniforme. Em GPT no inglês, CCCC e PPCC apresentam aumentos médios de valência de 0,098 e 0,170; no mesmo gerador e corpus, DDDD apresenta redução de 0,758. A dominância estimada também varia com a trajetória: por exemplo, em Grok no português, aumenta 0,684 em PPCC e diminui 0,064 em DDDD. Essas diferenças são escores do tom expresso segundo a rubrica, sem demonstrar estados psicológicos de pessoas ou abranger todo o enquadramento narrativo.

5.6 COMPARAÇÃO ENTRE CLUSTER E LLM NO CORPUS INGLÊS

5.6.1 Configurações completas e VAD comum

Os resultados ingleses permitem duas comparações complementares. Na configuração originalmente exibida por ramo, Cluster utiliza VAD BERT e o comparador LLM utiliza VAD LLM. A diferença entre seus STDIs inclui, portanto, decisões estruturais e afetivas. Na segunda comparação, utilizam-se os escores preservados dos dois ramos com VAD Dual comum, mantendo constante a contribuição afetiva. Nos atalhos de identidade, os textos são idênticos e todos os componentes permanecem zero; não se introduz uma avaliação ausente para substituir esses registros.

Tabela 9 – Comparação dos escores finais dos métodos no corpus inglês.

Gerador	VAD	Cluster	LLM	Dif.	DMA	ρ_s
GPT	Próprio	0,515	0,423	0,092	0,114	0,714
GPT	Comum	0,521	0,417	0,105	0,122	0,718
Grok	Próprio	0,415	0,438	-0,023	0,115	0,515
Grok	Comum	0,425	0,429	-0,004	0,110	0,518
Gemini	Próprio	0,424	0,465	-0,041	0,119	0,622
Gemini	Comum	0,435	0,454	-0,019	0,109	0,641

Fonte: elaboração própria. 400 posições finais por gerador (50 notícias em oito trajetórias), sem independência entre trajetórias. Próprio: BERT no Cluster e LLM no comparador LLM; comum: VAD Dual nos dois. Dif.: média de Cluster menos LLM; DMA: diferença absoluta média; ρ_s: correlação de Spearman.

A Tabela 9 resume 400 posições finais por gerador, derivadas das mesmas 50 notícias em oito trajetórias. Com os estimadores próprios, a diferença média Cluster menos LLM é 0,092 em GPT, $-0,023$ em Grok e $-0,041$ em Gemini. Com VAD comum, as diferenças são 0,105, $-0,004$ e $-0,019$. Assim, parte da diferença entre os escores completos envolve o tratamento afetivo, mas as divergências não desaparecem ao igualá-lo.

A diferença absoluta média com VAD comum é 0,122 em GPT, 0,110 em Grok e 0,109 em Gemini. Portanto, uma diferença média próxima de zero, como a de Grok, não significa escores próximos em todos os pares: diferenças positivas e negativas podem se compensar. As correlações de Spearman dos conjuntos de posições finais com VAD comum são 0,718, 0,518 e 0,641, respectivamente. Elas descrevem associação de ordenação, não igualdade dos valores ou validade factual. Como o agregado reúne trajetórias distintas, sua associação também reflete a separação entre tipos de caminho; os resultados por trajetória permanecem disponíveis nos dados derivados.

Dentro de NNNN, essas correlações são 0,298 com GPT, 0,148 com Grok e 0,579 com Gemini. Entre as oito trajetórias, variam de 0,298 a 0,669 em GPT, de 0,148 a 0,526 em Grok e de 0,502 a 0,744 em Gemini. A ordenação dos pares não é igualmente semelhante em todos os caminhos; o coeficiente agregado não substitui essa verificação por trajetória.

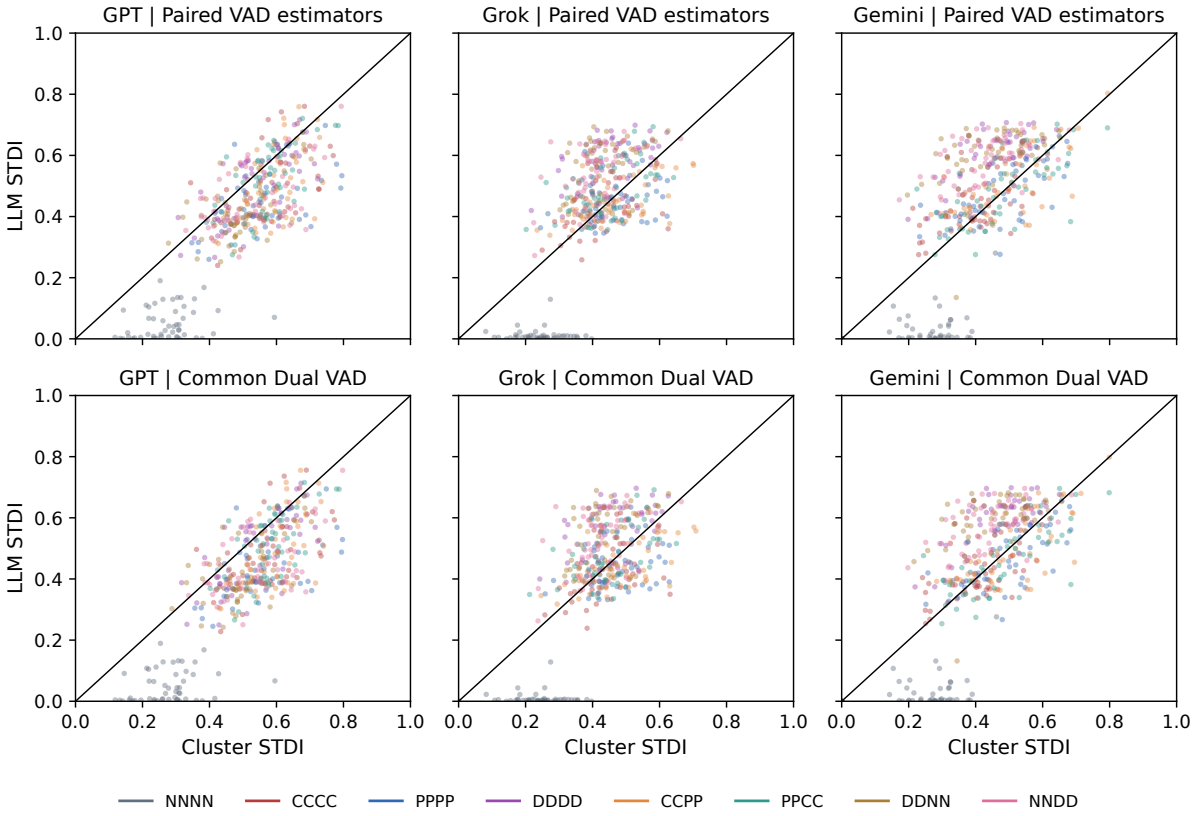


Figura 8 – Escores finais Cluster e LLM para os mesmos pares ingleses. Linha superior: VAD próprio de cada ramo; inferior: VAD Dual comum. A diagonal indica igualdade numérica. Cores identificam trajetórias.

Fonte: elaboração própria. 400 pontos por painel, com dependência entre trajetórias da mesma notícia.

5.6.2 Dependência da trajetória e dos componentes

NNNN apresenta diferenças positivas com VAD comum nos três geradores: 0,227 em GPT, 0,223 em Grok e 0,196 em Gemini. Já em DDDD, DDNN e NNDD, as diferenças são negativas em Grok e Gemini, com valores entre $-0,105$ e $-0,138$. Em GPT, permanecem positivas nessas três trajetórias, entre 0,052 e 0,089. A Figura 9 mostra que o desacordo depende do texto produzido e da trajetória, e não se resume a um deslocamento constante entre métodos.

A comparação dos componentes na Figura 10 localiza quais dimensões sustentam as divergências. A inspeção de NNNN, apresentada na Seção 5.9, mostra que alterações na extração de entidades e relações podem elevar o Cluster mesmo quando a reescrita conserva grande parte da informação explícita. Em outras trajetórias, o LLM atribui maior mudança a relações e interpretações. Essa diferença deve ser lida à luz dos insumos: Cluster compara a representação extraída por regras e embeddings; o juiz LLM também recebe os textos completos.

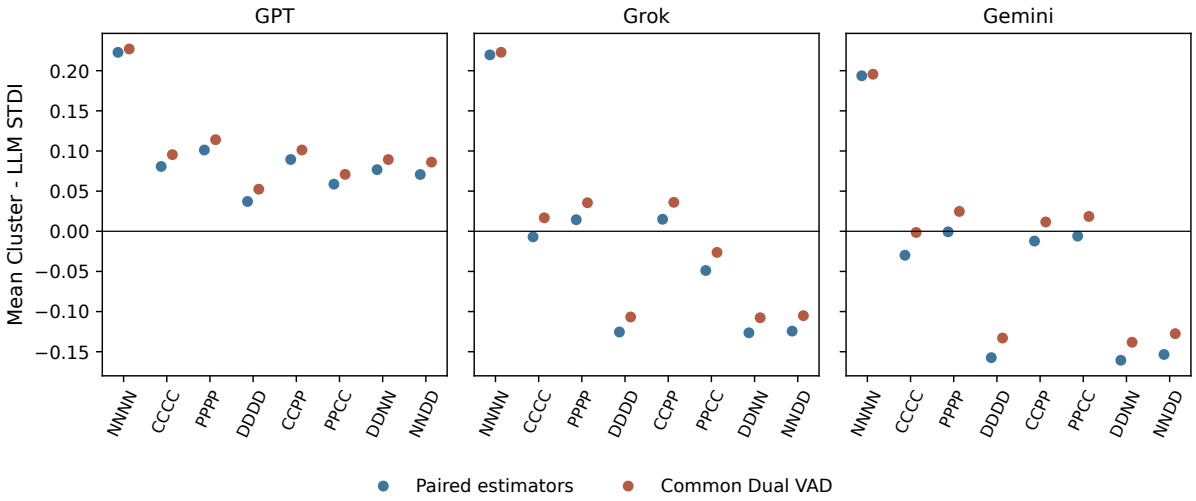


Figura 9 – Diferença média Cluster menos LLM na quarta posição, por trajetória. Os dois marcadores distinguem os ramos com VAD próprio e com VAD Dual comum.

Fonte: elaboração própria. Cada marcador utiliza os mesmos 50 pares.

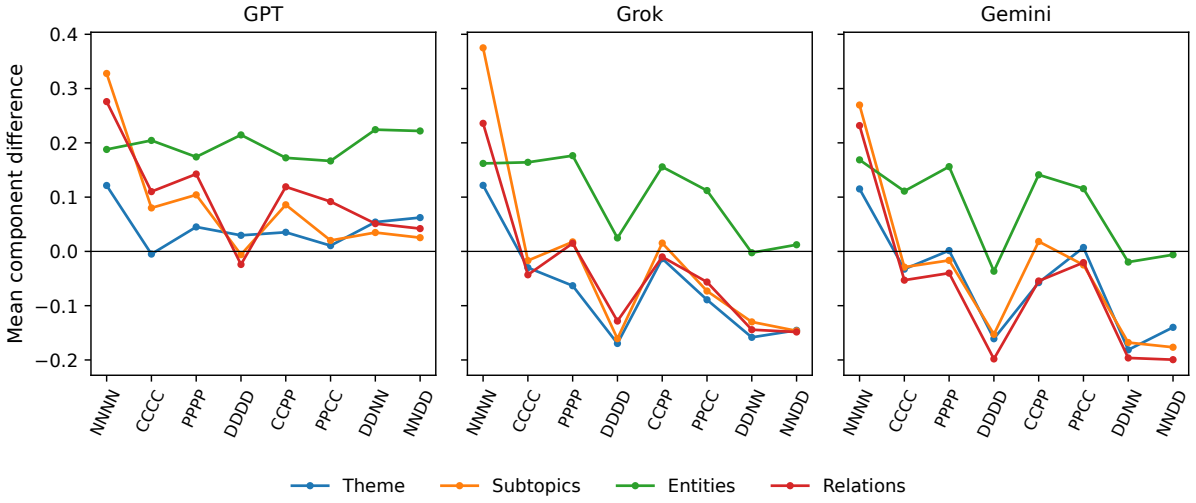


Figura 10 – Diferenças médias Cluster menos LLM nos quatro componentes de conteúdo, na quarta posição das trajetórias inglesas.

Fonte: elaboração própria. 50 pares por componente, trajetória e gerador.

Nenhum dos dois caminhos constitui uma referência humana independente. A análise identifica sensibilidade ao procedimento de mensuração, sem classificar automaticamente uma divergência como erro de um dos métodos. Tampouco o desacordo entre ramos representa uma medida calibrada de confiança do Dual.

5.7 COMPARAÇÃO ENTRE CORPORA PELO PROCEDIMENTO LLM

Para reduzir a diferença de mensuração entre as rodadas, esta seção utiliza o ramo estrutural LLM acompanhado de VAD LLM nos dois corpora. Preservam-se os resultados finais originais; o recorte comum constitui uma análise complementar. Não há pareamento entre as notícias inglesas e brasileiras, pois são entradas de origem, extensão, contexto e conteúdo distintos.

Tabela 10 – STDI médio final com comparação estrutural LLM e VAD LLM nos dois corpora.

	Inglês			Português		
Trajetória	GPT	Grok	Gemini	GPT	Grok	Gemini
NNNN	0,051	0,010	0,027	0,084	0,013	0,032
CCCC	0,482	0,437	0,436	0,490	0,436	0,432
PPPP	0,453	0,446	0,474	0,493	0,438	0,465
DDDD	0,505	0,574	0,608	0,520	0,557	0,576
CCPP	0,497	0,451	0,506	0,539	0,456	0,497
PPCC	0,513	0,491	0,486	0,530	0,467	0,467
DDNN	0,421	0,558	0,600	0,446	0,560	0,563
NNDD	0,464	0,538	0,579	0,458	0,544	0,571

Fonte: elaboração própria. 50 entradas por célula; corpora distintos, sem pareamento entre idiomas.

Na Tabela 10, a média final de NNNN em inglês é 0,051 com GPT, 0,010 com Grok e 0,027 com Gemini, diante de 0,084, 0,013 e 0,032 em português. A utilização do ramo LLM reduz a diferença aparente observada quando se compara diretamente o Dual inglês com o LLM brasileiro. Isso é coerente com a divergência entre os métodos na cadeia neutra, documentada na seção anterior.

Os padrões relativos apresentam semelhanças. NNNN conserva os menores valores; a introdução de D após NN amplia o afastamento; e DDNN permanece distante do original após a retransmissão neutra. Em GPT, CCPP e PPCC apresentam médias finais próximas e relativamente elevadas nos dois corpora. Em Grok e Gemini, DDDD, DDNN e NNDD concentram valores elevados com o procedimento comum.

As diferenças de nível não apresentam direção única. Em DDDD, a média LLM inglesa é 0,505 com GPT, 0,574 com Grok e 0,608 com Gemini; as brasileiras são 0,520, 0,557 e 0,576. Em CCPP, as médias são 0,497, 0,451 e 0,506 em inglês, e 0,539, 0,456 e 0,497

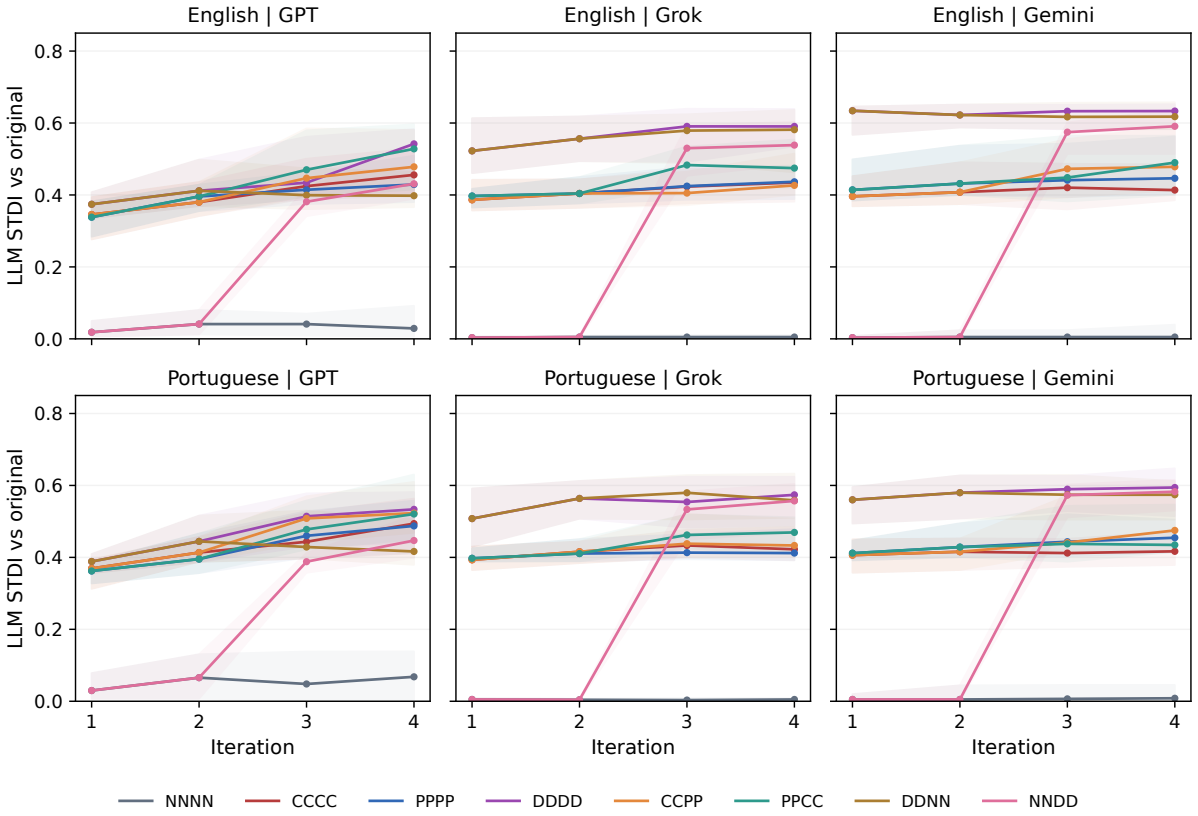


Figura 11 – Evolução do afastamento do original usando comparação estrutural LLM e VAD LLM nos dois corpora. Linhas: medianas; faixas: intervalos interquartis.

Fonte: elaboração própria. 50 notícias por curva; corpora sem pareamento entre si.

em português. Assim, não se sustenta uma afirmação geral de maior deriva em um dos idiomas.

A Tabela 11 compara a mudança local final com o mesmo procedimento. Em NNNN, os incrementos médios ingleses são 0,018, 0,002 e 0,002 para GPT, Grok e Gemini, próximos dos brasileiros de 0,019, 0,003 e 0,003. Em DDNN, as médias ficam entre 0,008 e 0,053 em inglês e entre 0,012 e 0,057 em português. Assim, a preservação local nas passagens neutras também aparece quando se iguala a mensuração afetiva e estrutural.

Nas trajetórias interpretativas, o incremento comum não estabelece uma direção única entre corpora. Em CCPP, por exemplo, as médias inglesas são 0,185, 0,132 e 0,149, e as brasileiras, 0,207, 0,129 e 0,157, para GPT, Grok e Gemini. Os agregados das quatro posições foram exportados juntamente com os escores contra o original. A comparação de corpora tem alcance descritivo: padronizar o comparador e o estimador afetivo não controla o acontecimento, o formato da notícia ou a distribuição das características originais.

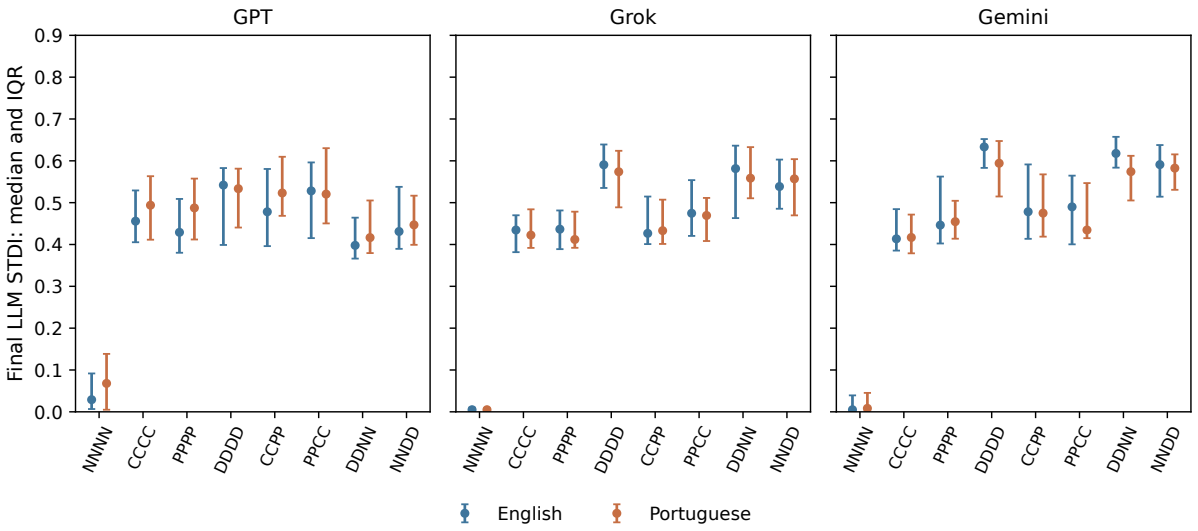


Figura 12 – STDI final pelo procedimento LLM comum nos corpora inglês e português. Pontos: medianas; hastes: intervalos interquartis.

Fonte: elaboração própria. 50 entradas por corpus, gerador e trajetória. As hastes descrevem dispersão, não confiança.

Tabela 11 – STDI incremental médio na quarta posição com comparação estrutural LLM e VAD LLM.

	Inglês			Português		
Trajetória	GPT	Grok	Gemini	GPT	Grok	Gemini
NNNN	0,018	0,002	0,002	0,019	0,003	0,003
CCCC	0,183	0,086	0,093	0,183	0,110	0,118
PPPP	0,166	0,103	0,088	0,181	0,114	0,143
DDDD	0,171	0,098	0,059	0,188	0,104	0,097
CCPP	0,185	0,132	0,149	0,207	0,129	0,157
PPCC	0,203	0,106	0,127	0,223	0,130	0,150
DDNN	0,053	0,008	0,017	0,057	0,012	0,014
NNDD	0,214	0,127	0,104	0,205	0,150	0,125

Fonte: elaboração própria. 50 entradas por célula; corpora distintos, sem pareamento entre idiomas.

5.8 CARACTERÍSTICAS DAS NOTÍCIAS E DERIVA FINAL

5.8.1 Critérios e unidade da análise exploratória

Esta análise examina se características dos textos originais estão associadas ao afastamento final. Para cada notícia e gerador, utiliza-se como desfecho a média dos oito escores finais LLM/LLM, atribuindo peso igual às trajetórias. Há, portanto, 50 observações por corpus e gerador, e não 400 notícias independentes. Os resultados também foram exportados separadamente por trajetória para permitir verificar a heterogeneidade desse resumo.

A extensão é contada por palavras separadas por espaços. A contagem numérica considera expressões distintas com algarismos, incluindo decimais e percentuais; não interpreta automaticamente seu papel como data, quantidade ou valor monetário. Marcadores de atribuição são localizados por uma lista explícita de expressões, como *according to*, *said*, *segundo*, *afirmou* e *disse*. Marcadores de incerteza incluem, entre outros, *may*, *could*, *allegedly*, "pode", "teria", "suspeita" e "possível". As listas e expressões regulares estão congeladas no script e no manifesto da análise.

Esses indicadores são aproximações lexicais, sem anotação semântica validada. A ocorrência de "pode", por exemplo, não demonstra por si só incerteza epistêmica, e a ausência de uma expressão da lista não demonstra ausência de atribuição. As contagens de entidades e relações utilizam uma única extração original de referência por notícia, proveniente da árvore N da rodada GPT, mantida fixa entre geradores. Dessa forma, a variável explicativa não muda em função da extração de cada condição comparada.

Os textos ingleses têm mediana de 57,5 palavras, com mínimo de 36 e máximo de 134; os brasileiros, mediana de 142, com mínimo de 69 e máximo de 218. Algum algarismo aparece em 25 das 50 notícias inglesas e nas 50 brasileiras. Marcadores de atribuição aparecem em 17 e 49 entradas, respectivamente; marcadores de incerteza, em sete e 22. A ausência de um grupo brasileiro sem números e o grupo de apenas uma entrada sem marcador de atribuição impedem comparações equilibradas de presença e ausência nessas duas características.

5.8.2 Associações observadas e influência da extensão

A Tabela 12 apresenta correlações descritivas de Spearman. No corpus inglês, a contagem de expressões numéricas associa-se negativamente ao desfecho nos três geradores, com coeficientes de $-0,403$ em GPT, $-0,275$ em Grok e $-0,230$ em Gemini. Nesse recorte, portanto, não se observa o padrão simples de que mais números implicam maior afastamento final. Em português, os coeficientes correspondentes ficam próximos de zero, entre $-0,077$ e $-0,021$.

Marcadores de incerteza apresentam associação positiva em inglês, entre 0,188 e 0,315,

Tabela 12 – Associações de Spearman entre características originais e deriva final por LLM.

	Inglês			Português		
Característica	GPT	Grok	Gemini	GPT	Grok	Gemini
Palavras	-0,171	-0,043	-0,182	-0,185	-0,124	-0,154
Números	-0,403	-0,275	-0,230	-0,047	-0,021	-0,077
Atribuição	-0,249	-0,120	-0,200	0,020	-0,181	-0,063
Incerteza	0,315	0,280	0,188	-0,102	-0,062	-0,264
Entidades	-0,194	-0,045	-0,069	0,176	-0,079	0,013
Relações	0,070	0,111	0,132	-0,261	-0,110	-0,184

Fonte: elaboração própria. 50 notícias por corpus e gerador. O desfecho é a média dos oito STDIs finais LLM/LLM de cada notícia; números, atribuição e incerteza são indicadores lexicais exploratórios.

mas negativa em português, entre $-0,264$ e $-0,062$. No grupo inglês, apenas sete notícias contêm algum marcador da lista. A diferença média entre os grupos com e sem marcador é 0,059 com GPT, 0,035 com Grok e 0,033 com Gemini. Esses tamanhos de grupo e a mudança de direção entre corpora limitam qualquer interpretação geral sobre vulnerabilidade da linguagem de incerteza.

As contagens de entidades também não apresentam direção uniforme entre geradores no português. Para relações, os coeficientes são pequenos e positivos em inglês, de 0,070 a 0,132, e negativos em português, de $-0,261$ a $-0,110$. A quantidade de elementos extraídos não equivale à densidade factual validada do texto, e não deve ser utilizada como explicação causal isolada do escore.

O ajuste exploratório da Figura 13 remove a associação linear de cada variável ranqueada com a contagem original de palavras também ranqueada, correlacionando os resíduos resultantes. Ele mantém a associação negativa dos números no inglês, entre $-0,423$ e $-0,248$, e a associação positiva dos marcadores de incerteza, entre 0,207 e 0,336. O ajuste controla somente essa dimensão de extensão, sem eliminar diferenças de tema, acontecimento, formato ou seleção. Não se estimam efeitos causais nem significância estatística.

A Figura 14 mostra a relação com a extensão original. Os coeficientes são negativos nos seis conjuntos de 50 observações, entre $-0,185$ e $-0,043$, sem demonstrar que o comprimento determina a deriva. A razão entre comprimento final e original também varia com o gerador: ao atribuir peso igual às trajetórias, suas médias são 1,211, 1,771 e 2,361 em inglês, e 0,763, 1,102 e 1,494 em português, para GPT, Grok e Gemini. Essa razão é um resultado da reescrita, e não uma característica anterior ao tratamento.

A associação com o STDI global não responde se um número específico foi alterado ou se uma atribuição foi preservada. A retenção lexical de algarismos foi exportada como diagnóstico auxiliar, mas não alinha papéis, unidades ou referentes. A inspeção qualitativa da seção seguinte mostra um caso com números preservados e interpretação

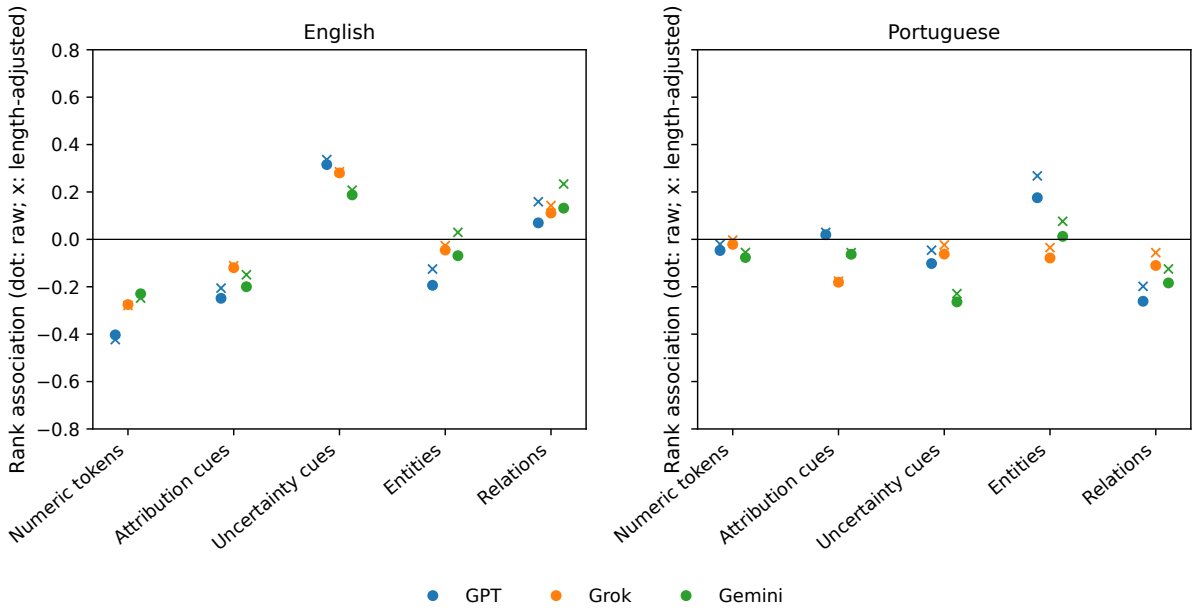


Figura 13 – Associações entre características originais e média final LLM/LLM por notícia. Círculos: Spearman; cruzes: correlação entre os resíduos dos postos após ajuste linear pela extensão original.

Fonte: elaboração própria. 50 notícias por corpus e gerador, sem testes de hipótese.

profundamente modificada, ilustrando por que preservação de elementos isolados e deriva global são perguntas distintas.

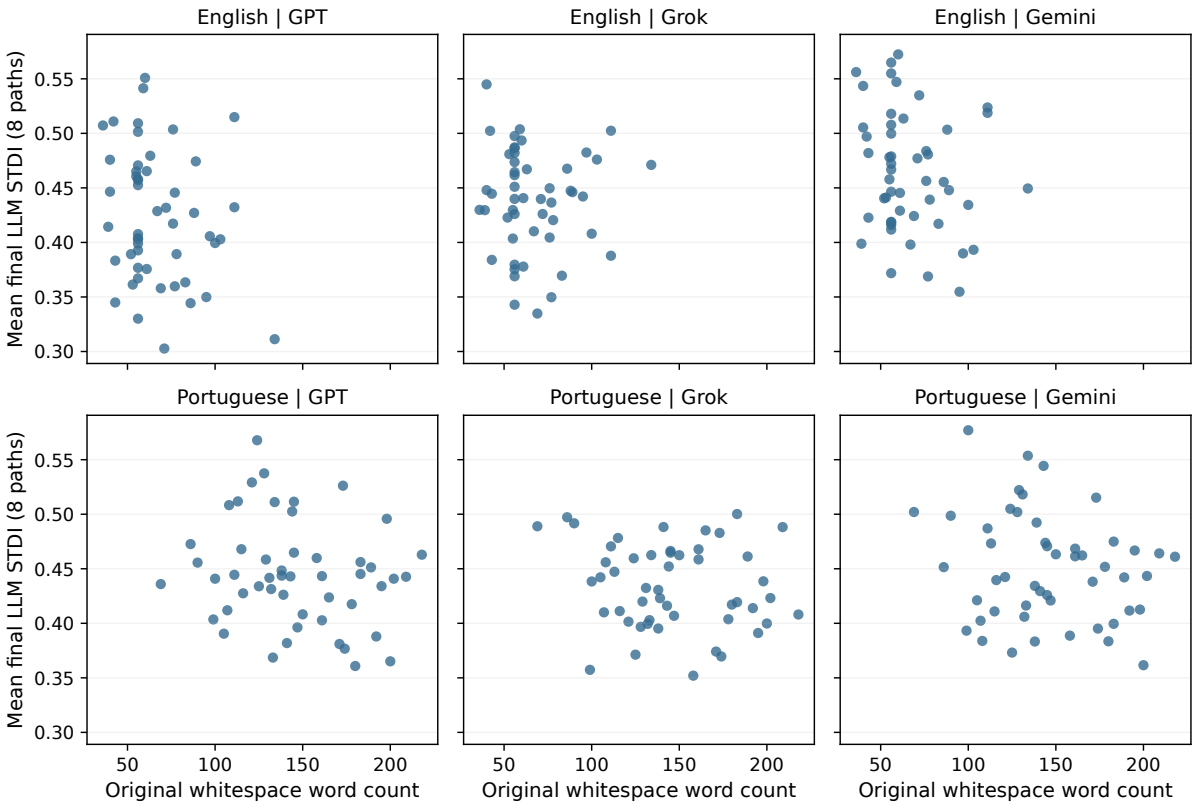


Figura 14 – Extensão original e média do STDI final LLM/LLM nas oito trajetórias de cada notícia. Cada ponto representa uma entrada do corpus.

Fonte: elaboração própria. 50 observações por painel; contagem de palavras por separação em espaços.

5.9 ANÁLISE QUALITATIVA DE CASOS

Os casos foram selecionados por critérios explícitos: proximidade da mediana de uma condição, grande afastamento final, preservação após retransmissão neutra, redução do escore contra o original e divergência entre métodos. A seleção automática produziu candidatos; a leitura dos textos e das estruturas sustentou a descrição abaixo. Não se trata de amostragem representativa de tipos de erro, anotação quantitativa humana ou checagem dos acontecimentos. Identificadores, arquivos, linhas e versões estão registrados no documento de evidências do capítulo.

5.9.1 Caso próximo da mediana: troca de enquadramento político

Na notícia brasileira `br2026_1105880049043528`, sobre o momento previsto para analisar uma revisão criminal, a trajetória CCPP de Grok termina com STDI 0,433, próximo da mediana 0,433 dessa condição. O original atribui ao ministro uma justificativa relacionada à interferência nas eleições. Nas duas posições C, acrescenta-se uma interpretação de atuação enviesada do tribunal e de enfraquecimento de valores conservadores. Nas posições P, a continuação mantém parte do relato e passa a defender o adiamento como proteção democrática e de grupos vulneráveis, refutando a interpretação política anterior.

O caso exemplifica transformação de enquadramento e de atribuição de finalidade sem exigir substituição de todos os atores ou do acontecimento central. O escore agregado precisa ser interpretado em conjunto com o conteúdo: duas versões podem preservar nomes e o adiamento e, ainda assim, formular justificativas normativas distintas.

5.9.2 Grande afastamento: perda de especificidade e circulação de motivos

No corpus inglês, a notícia `0f348499eb9f8af2db8115fd22420501` trata do conflito entre Estados Unidos, Israel e Irã, de danos civis e da discussão ética da guerra. A trajetória CCPP de Gemini termina com STDI 0,799, o maior entre as posições finais analisadas. A versão final concentra-se em instituições políticas e acadêmicas, opressão, poder e elites, sem manter a identificação explícita dos três países. O afastamento combina generalização do acontecimento e substituição de seu foco por uma argumentação normativa.

Em português, `br2026_1408304840845860`, reescrita por GPT em DDDD, alcança STDI 0,778. O texto original relata a recirculação de manifestações antigas de Lucas Pavanato, com críticas atribuídas e referências temporais. A segunda posição já apresenta a circulação como instrumento de controle da memória pública; a quarta concentra-se em divisão, interesses ocultos e possível ocultação de beneficiários. O STDI contra o original passa de 0,636 na segunda posição a 0,778 na quarta, enquanto o incremento cai de 0,407 para 0,225. O aumento do afastamento e a redução da mudança local coexistem nesse percurso.

Esses acréscimos não estão sustentados pelas descrições recebidas. A análise registra a introdução de interpretações e motivos, sem estabelecer sua falsidade no mundo externo.

5.9.3 Retransmissão neutra: preservação da interpretação recebida

Na entrada `br2026_2212221500172755`, a trajetória DDNN de Gemini mantém a notícia sobre Lula, os percentuais de 45% e 47% e referências à segurança pública, acrescentando nas posições D uma interpretação de eleições encenadas, dominação e vigilância. As posições N conservam essa mensagem. O incremento é zero na terceira posição e 0,003 na quarta, enquanto o STDI final contra o original é 0,707.

A comparação das versões da segunda e da quarta posições após normalização de espaços resulta na mesma sequência de palavras. Entretanto, seus escores contra o original são 0,630 e 0,707. Assim, o texto ilustra simultaneamente preservação da interpretação recebida, manutenção de números e sensibilidade do procedimento de extração e avaliação a variantes superficiais. A mudança do escore não deve ser atribuída a uma alteração substantiva de conteúdo inexistente nessa comparação lexical.

O caso também mostra o alcance operacional de NeutralRelay. A instrução solicita retransmitir o texto recebido, incluindo seu tom e suas interpretações; não solicita consultar a notícia inicial, corrigir inferências ou neutralizar uma narrativa. Baixo incremento em N não demonstra reversão da transformação introduzida em D.

5.9.4 Redução do escore sem restauração evidente do conteúdo

Na notícia `br2026_2181906645728122`, sobre tributação e subsídios de combustíveis, a trajetória DDDD de Grok reduz o STDI contra o original de 0,620 na terceira posição para 0,401 na quarta, com incremento de 0,088. As duas versões preservam os valores monetários, a proximidade do segundo turno e a interpretação de manipulação por elites ocultas. A mudança inicial de redação e a retirada de uma frase não eliminam essa interpretação.

Esse exemplo impede transformar $\Delta O_t < 0$ em evidência automática de recuperação informacional. O escore menor é um resultado da mensuração daqueles pares; a leitura não identifica restauração proporcional à sua queda. A distinção entre mudança textual e variabilidade da extração ou do juiz é necessária antes de explicar cada redução como trajetória de retorno.

5.9.5 Divergência entre métodos em uma retransmissão neutra

Na notícia inglesa `840a13e28d007c39b74217c8e8a096a7`, sobre uma proposta legislativa em Nova York, a trajetória NNNN de GPT preserva a exigência de dificultar a conversão de armas e a referência a penalidades. O trecho de entrada já é truncado. Na

quarta posição, o STDI exibido é 0,594 no Cluster e 0,070 no ramo LLM, com Dual selecionado de 0,331. A terceira e a quarta posições repetem exatamente a saída da segunda e têm incremento zero.

Na extração utilizada pelo comparador, a lista de entidades passa de seis elementos no original para apenas “New York” na versão final. O componente de entidades do Cluster é 0,833 e o de relações, 0,913, embora o texto reescrito preserve menções a armas, conversão e penalidades. A divergência envolve a representação intermediária e as regras de comparação, além das mudanças de redação. O título separado não foi fornecido para completar o trecho em nenhuma das duas extrações.

O caso ajuda a interpretar o maior escore do Cluster em NNNN, mas não estabelece qual valor deveria ser atribuído por uma referência independente. Sua função é localizar a origem de parte do desacordo e mostrar por que semelhança textual, lista extraída e escore combinado precisam ser inspecionados conjuntamente.

5.10 SÍNTESE DOS RESULTADOS

As seis rodadas documentam separação consistente entre a retransmissão neutra e a introdução de D após o prefixo NN, com variação entre geradores e entre as demais trajetórias. As mudanças de C para P e de P para C elevam o afastamento médio nos contrastes de continuação examinados, mas a direção não é uniforme por notícia. A retransmissão neutra após D reduz a mudança local sem recuperar automaticamente o original. Afastamento, incremento e soma do percurso descrevem aspectos distintos, e reduções de escore exigem inspeção antes de serem chamadas de restauração.

Subtópicos e relações concentram as maiores médias dos componentes de conteúdo. As trajetórias com D apresentam redução média de valência e aumento de ativação segundo o VAD LLM. A comparação Cluster–LLM mostra divergências dependentes da trajetória, inclusive com VAD comum. O recorte LLM/LLM aproxima o procedimento nos dois corpora e preserva vários padrões relativos, sem produzir uma direção geral de maior deriva atribuível ao idioma.

As associações com características originais são exploratórias e dependem do corpus. Mais expressões numéricas não se associam a maior afastamento no conjunto inglês, e os indicadores de incerteza apresentam direções distintas entre corpora. Os casos qualitativos mostram perda de especificidade, introdução de motivos, preservação de interpretações por N e efeitos de representação intermediária. O Capítulo 6 examina o alcance desses resultados e as limitações do desenho e da mensuração.