

Deriva informacional em cadeias de reescrita de notícias por agentes baseados em LLMs

Um índice estruturado para analisar transformações de notícias por LLMs

Trabalho de Conclusão de Curso • 2026 • Defesa: A PREENCHER

Luiz Cláudio Vieira Filho

Orientador: Paulo Mann · Coorientador: Fabricio Goes · Banca: A PREENCHER

Roteiro da apresentação

1

Problema

motivação,
pergunta e
objetivos

2

Fundamentação

auditorias,
literatura e STDI

3

Método

corpus, atributos e
cadeias

4

Resultados

cenários, domínios
e exemplo


5

Conclusão

limitações e
contribuições

Duração planejada: 25–30 minutos, deixando a arguição para a banca.

Reescritas sucessivas podem alterar a notícia sem inventar um fato explícito



Motivação científica

Uma decisão falsa/verdadeira não mostra qual dimensão mudou nem como a transformação evoluiu ao longo da cadeia.

Base da motivação

Evolução do conteúdo

Mutações na circulação e distorção iterativa.

Zhang et al. (2013); Guo et al. (2021); Mohamed et al. (2025); Liu et al. (2025).

Pergunta de pesquisa e recorte

Em que medida a ordem e o tipo de perspectiva atribuída a agentes LLM alteram o conteúdo e o enquadramento emocional de uma notícia ao longo de uma cadeia de reescritas?

Unidade de análise

Notícias e suas versões reescritas, em testes isolados e em cadeias com diferentes perspectivas.

Limite do estudo

O índice mede mudança textual. Não verifica fatos externos nem comportamento de leitores.

Objetivos e hipóteses

Objetivo geral

Desenvolver e avaliar um procedimento estruturado para medir a deriva informacional e afetiva em cadeias controladas de reescrita de notícias por agentes baseados em LLMs.

Perguntas analíticas

O que será comparado

- O tipo e a ordem das perspectivas estão associados à deriva?
- Quais componentes do STDI e do VAD mudam nas cadeias?
- Como o domínio temático se relaciona com a deriva?

Objetivos específicos: caracterizar o limite das auditorias binárias; definir o STDI; analisar VAD; comparar sequências e domínios.

O BERT transformava o par de textos em uma decisão binária

Primeiro teste: o detector pré-treinado recebia apenas a reescrita e retornava falsa ou verdadeira.

1 Par de entrada

Original como
premissa
+
Reescrita como
hipótese

2 Modelo NLI

Tokenizer +
mDeBERTa
Máximo de 512
tokens
com truncamento

3 Probabilidades

Suporte
Neutralidade
Contradição

4 Regra binária

Contradição $\geq 0,60$ e
contradição – suporte $\geq 0,20$

Se a regra fosse satisfeita: potencialmente falsa após a reescrita. Caso contrário: consistente com o original.

Textos longos tornam a comparação global difícil de interpretar

O que o NLI entregava

Uma distribuição global para o par inteiro e, ao final, um rótulo binário. Entradas acima de 512 tokens eram truncadas.

O que precisávamos observar

Onde ocorreu a mudança: assunto, aspectos secundários, atores, relações, consistência interna e tom afetivo.

Tema

Subtópicos

Entidades

Relações

Contradição

VAD

Essa lacuna motivou o STDI: decompor a transformação antes de calcular uma pontuação agregada.

O trabalho articula quatro linhas de pesquisa

Enquadramento

Desinformação e enquadramento

Seleção, saliência e enquadramento moldam a leitura.

(Entman, 1993; Lazer et al., 2018)

Representação

NLI e similaridade semântica

NLI é global; embeddings apoiam a comparação semântica.

(Reimers & Gurevych, 2019; Su et al., 2024)

Dimensão afetiva

VAD e linguagem afetiva

Valência, arousal e dominância descrevem emoção no texto.

(Buechel & Hahn, 2017; Mohammad, 2018)

Cadeias de agentes


LLMs e cadeias de agentes

Geração iterativa e personas alteram trajetórias textuais.

(Chuang et al., 2024; Mohamed et al., 2025; Liu et al., 2025)

Lacuna a explicitar: faltam medidas interpretáveis para acompanhar deriva de conteúdo e afeto em reescritas sucessivas.

Cada versão é reescrita sob uma perspectiva e alimenta a próxima etapa



1 · Entrada

Primeira posição: recebe a notícia original.

Posições seguintes: recebem a saída da posição anterior.

2 · Restrições do prompt

Preservar: conteúdo factual explícito e idioma solicitado.

Não inventar: dados, números, citações, eventos ou personagens.

3 · Transformação permitida

Alterar: enquadramento, ênfase, tom, vocabulário e foco narrativo.

Saída: somente o texto reescrito, sem explicações ou rótulos.

Efeito acumulativo A cadeia mantém o contexto de título e idioma, mas cada nova reescrita parte da versão produzida anteriormente.

O LLM converte cada texto em uma estrutura comparável

Fluxo de extração

- 1 Título + texto
- 2 Prompt fixo (temperatura 0,1)
- 3 JSON com chaves pré-definidas
- 4 Validação, normalização e remoção de duplicatas

Campos de conteúdo

main_topic assunto principal

subtopics temas e ângulos secundários

central_entities pessoas, organizações, lugares e grupos

central_relations triplas sujeito · ação · objeto

Campos de contexto e diagnóstico

topic_domain domínio temático controlado

narrative_frame enquadramento dominante

has_internal_contradiction presença de contradição interna

internal_contradiction_score intensidade entre 0 e 1

A extração descreve o que está no texto.
Ela não consulta fontes externas e não determina veracidade factual.

O LLM atribui um domínio primário do vocabulário controlado IPTC Media Topics

topic_domain: um dos 17 domínios controlados de IPTC Media Topics.

arts_culture_entertainment_and_media

conflict_war_and_peace

crimeLaw_and_justice

disaster_accident_and_emergency_incident

economy_business_and_finance

education

environment

health

human_interest

labour

lifestyle_and_leisure

politics

religion_and_belief

science_and_technology

society

sport

weather

O domínio é extraído do texto pelo LLM. Use null somente quando não for possível determinar o domínio.

A comparação evoluiu de sobreposição lexical para similaridade semântica

Primeira versão · Jaccard

$$D_J(A,B) = 1 - |\text{interseção}| / |\text{união}|$$

Aplicação: subtópicos, entidades e triplas de relações já extraídas pelo LLM.

Tema: distância 0 para igualdade normalizada; 1 para qualquer diferença.

Limite: paráfrases semanticamente próximas podiam parecer totalmente diferentes.



Versão vigente · embeddings

Representação: all-MiniLM-L6-v2 converte os elementos extraídos em vetores.

Comparação: similaridade por cosseno e pareamento guloso entre listas.

Relações: texto completo + sujeito + ação + objeto, com pesos internos fixos.

Agrupamento: K-means compartilhado e semente 42 apoiam inspeção e reprodução.

Domínio temático

O LLM escolhe uma categoria controlada. Se os dois domínios conhecidos diferem, a similaridade de tema é zerada. O domínio permite auditar cobertura; não é site nem fonte.

O STDI separa dimensões da transformação

Tema

assunto principal

Subtópicos

aspectos abordados

Entidades

atores centrais

Relações

sujeito · ação · objeto

Contradição interna

Intensidade de inconsistências presentes na versão comparada.

VAD

Mudança de valência, arousal e dominância entre as versões.

Um LLM extrai a estrutura; embeddings, agrupamento e regras calculam as distâncias.

A fórmula combina conteúdo, contradição e afeto

Como o domínio entra no cálculo da deriva de tema

topic_domain (IPTC) → Dois domínios conhecidos e diferentes? → **Sim:** **similaridade de tema = 0** **D tema = 1** → **Não/ausente:** **similaridade semântica do main_topic**

$$C = 0,25 \times (D \text{ tema} + D \text{ subtópicos} + D \text{ entidades} + D \text{ relações})$$

$$C^c = C + (1 - C) \times 0,20 \times D \text{ contradição}$$

$$\text{STDI} = C^c + (1 - C^c) \times 0,20 \times D \text{ VAD}$$

D VAD = média das diferenças absolutas normalizadas de valência, arousal e dominância.

O domínio afeta somente D tema; ele não entra no cálculo de D VAD.

Contradição é interna ao texto comparado; STDI alto não equivale a falsidade factual.

A configuração do índice foi consolidada antes das cadeias

Casos controlados

50 pares com alterações dirigidas a tema, subtópico, entidade, relação, contradição ou VAD.

Métodos comparados

Avaliação semântica por LLM e comparação por embeddings, agrupamento e regras sobre as mesmas estruturas.

Decisão final

Pesos de conteúdo iguais; contradição e VAD como incrementos limitados; método de embeddings nas cadeias.

O STDl será mantido nessa configuração para preservar comparabilidade entre todos os cenários.

O experimento final usa uma amostra fixa de notícias em inglês

1.000

notícias elegíveis

50

notícias nas cadeias

inglês

idioma

53,5

mediana de palavras

Composição das 50 notícias

27 business; top

22 business

1 business; top; environment

Textos com 27–412 palavras.

Amostra documentada

Protocolo disponível

Amostra fixa: 50 de 1.000 notícias elegíveis, em inglês, com 27–412 palavras.

A concentração editorial em negócios limita a generalização e deve aparecer explicitamente na discussão.

Os experimentos cumprem funções complementares

Auditorias iniciais

Reescritas por diferentes LLMs e personas; detector pré-treinado e BERT/NLI.

Análises dos atributos

Casos controlados, regressão logística, VAD e comparação dos métodos de cálculo.


Simulação final

16 cenários com diferentes sequências de perspectivas aplicados às mesmas 50 notícias.

A sequência metodológica vai da limitação da classificação binária à análise estruturada das cadeias.

A regressão testou quais atributos distinguíam os grupos

Importância por permutação



Pergunta do teste

Os atributos extraídos carregam sinal para distinguir notícias falsas originais de versões reescritas?

Leitura

Arousal foi o sinal dominante. Extensão também pesa e deve ser tratada como possível fator de estilo.

500 originais + 500 reescritas; classes usadas como grupos de referência, não como verificação factual.

O sinal de arousal foi examinado diretamente em pares

A regressão apontou arousal como atributo mais informativo; a análise pareada ajuda a interpretar esse sinal.

Arousal médio




Queda em 21/24 pares • Δ médio = -0,196

Interpretação

Reescritas corretivas do mesmo tema ficaram menos ativadoras. A correção factual não foi verificada externamente.

A etapa final compara sequências de perspectivas

Cada cenário da simulação final contém quatro posições; isso não limita as demais reescritas realizadas no estudo.



C: conservadora · P: progressista · D: conspiratória · S: cética · E: emocional · M: conciliatória

STDI da 4ª reescrita em relação ao texto original; diferenças de ordem ainda incertas



Maior contraste pareado: CPCP – PCPC = +0,023; o intervalo de reamostragem ainda inclui zero.

A deriva também varia conforme o tipo de notícia



Políticas públicas tiveram média maior que negócios. Meio ambiente foi alto, mas contém somente duas notícias.

Médias por posição: STDI contra o original e acumulado

POSIÇÃO 1

Primeira reescrita

STDI vs. original: 0,211
Acumulado: 0,211

POSIÇÃO 2

Segunda reescrita

STDI vs. original: 0,236
Acumulado: 0,402

POSIÇÃO 3

Terceira reescrita

STDI vs. original: 0,251
Acumulado: 0,589

POSIÇÃO 4

Quarta reescrita

STDI vs. original: 0,256
Acumulado: 0,771

Média: distância final 0,211 → 0,256; acumulado 0,211 → 0,771.

Resultados extremos da simulação

VERSÃO FINAL

Maior STDI final

0,569 · CPMC, 4ª posição
Notícia sobre o mercado de serviços 5G.

PICO NA TRAJETÓRIA

Maior STDI vs. original

0,667 · CPCP, 2ª posição
O domínio temático mudou na reescrita.

CAMINHO ACUMULADO

Maior STDI cumulativo

1,771 · PCPC, 4ª posição
STDI final vs. original: 0,260.

Os extremos exigem inspeção qualitativa; não demonstram efeito geral de uma perspectiva.

Uma trajetória contrasta distância final e caminho cumulativo.

CASO 1 · TEXTO ORIGINAL

\$1.000 Dog Tax Credit

Promoção de marca de ração durante a temporada de impostos. Não é crédito governamental: participantes concorrem a um sorteio até abril.

CENÁRIO · SSSS

Quatro reescritas céticas

A cadeia esclarece que não há pagamento garantido. Mantém o domínio de negócios e reforça o alerta ao consumidor.

VERSÃO FINAL · 4ª REESCRITA

Texto final (trecho)

The \$1,000 Dog Tax Credit promotion may draw attention during tax season, but its wording could leave a misleading impression. It is not a government tax credit, but a limited-time sweepstakes offered by a pet food brand.

STDI final vs. original: 0,376 / Acumulado: 0,923

Exemplo SSSS, 4ª posição. A pontuação descreve mudança textual; não determina veracidade factual.

As conclusões dependem do corpus, dos modelos e da própria medida

Validade externa

50 notícias em inglês, com forte concentração em negócios.

Validade de construção

STDI mede deriva textual; não certifica verdade nem impacto sobre leitores.

Dependência de modelos

Extração estrutural, embeddings e VAD dependem de versões específicas.

Desenho estatístico

A mesma notícia aparece em vários cenários; comparações devem ser pareadas.

Síntese dos resultados atuais

1 Medida

O STDI descreve mudanças de conteúdo, contradição interna e afeto entre versões.

2 Atributos

A regressão encontrou sinal sobretudo em arousal; extensão do texto exige controle.

3 Perspectivas

As médias diferem entre cenários, mas os efeitos pareados de ordem ainda são incertos.

4 Domínios

Políticas públicas tiveram maior deriva média que negócios; grupos pequenos pedem cautela.

Estado atual: os resultados são exploratórios; atualizar somente se a execução final alterar os números ou a análise qualitativa.

Conclusão e contribuições

Resposta baseada nos resultados atuais

Conclusão provisória

Nas cadeias avaliadas, os cenários apresentaram médias de STDI diferentes, mas o maior contraste de ordem (CPCP – PCPC = +0,023) permaneceu incerto.

As médias também variaram por domínio, com grupos pequenos. Os resultados descrevem associações; não demonstram causalidade nem veracidade factual.

Contribuições do trabalho

1. STDI como medida estruturada e interpretável.
2. Pipeline reprodutível de reescrita e análise.
3. Desenho pareado de cadeias com diferentes perspectivas.
4. Diagnóstico exploratório de conteúdo, afeto, ordem e domínio.

Deriva mensurável não é sinônimo de falsidade.

Fontes e normas consultadas

Lazer et al. (2018). The Science of Fake News. Science.

Entman (1993). Framing: Toward Clarification of a Fractured Paradigm. Journal of Communication.

Mohamed et al. (2025). LLM as a Broken Telephone: Iterative Generation Distorts Information. ACL 2025.

Liu et al. (2025). The Stepwise Deception. EMNLP 2025.

Reimers & Gurevych (2019). Sentence-BERT. EMNLP-IJCNLP.

Buechel & Hahn (2017). EmoBank. EACL.

Demais referências: Chuang et al. (2024); Su, Cardie & Nakov (2024); Mohammad (2018); Chen et al. (2025); Abdurahman et al. (2025).

Base completa: references.bib.



MATERIAL PARA ARGUIÇÃO

Slides de apoio

Detalhes técnicos, cenários, sensibilidade e exemplos adicionais

Modelos e função no pipeline

gpt-5.6-luna

reescrita e extração estrutural

Fake-News-Bert-Detect

classificação isolada falsa/verdadeira

mDeBERTa MNLI/XNLI

consistência entre original e reescrita

vad-bert

valência, arousal e dominância

all-MiniLM-L6-v2

embeddings para comparação estrutural

A PREENCHER — registrar revisão,
parâmetros e data de cada execução.

Os 16 cenários formam contrastes planejados

Referência e homogêneos

SSSS
CCCC · PPPP · DDDD

Perspectivas C/P

CCPP ↔ PPCC
CPCP ↔ PCPC

Perspectivas D/S

DDSS ↔ SSDD
DSDS ↔ SDSD

Posição de E e M

DDES ↔ DDSE
CMPC ↔ CPMC

C: conservadora · P: progressista · D: conspiratória · S: cética · E: emocional · M: conciliatória

Experimento TF-IDF: forte sinal lexical, interpretação cautelosa

Objetivo

Testar se termos e expressões diferenciam os grupos de referência.

Representação

TF-IDF de unigramas e bigramas até 10.000 atributos · min_df = 5

Mesmo teste

Regressão logística
750 treino · 250 teste
holdout separado por notícia

Resultado

AUC-ROC
STDI: 0,921 · TF-IDF: 1,000
STDI + TF-IDF: 0,980

Exemplos de n-gramas mais influentes no TF-IDF

N-gramas com coeficiente positivo

**criticism · criticized
2017 · had · did not**

N-gramas com coeficiente negativo

**is · this · just
via · even**